

GUARDIÃ AI

Apoio à triagem de risco materno

Relatório técnico — Tech Challenge Fase 5

Dados + Machine Learning + LLM + RAG + aplicação

Versão 1.0.0

Gerado em 14 de agosto de 2026

Cenário: saúde da mulher — triagem de risco durante a gestação

1. Problema e objetivo

A Guardiã AI recebe seis indicadores de uma gestante, executa um modelo de classificação de risco, recupera sínteses rastreáveis de documentos oficiais e produz uma explicação destinada ao profissional responsável pelo atendimento. O produto implementa uma jornada completa, da entrada dos dados ao registro auditável do resultado.

O sistema é exclusivamente um apoio à triagem. Não realiza diagnóstico, não prescreve medicamentos e não toma decisões clínicas ou de segurança de forma automática. A decisão final permanece humana.

Escopo funcional

- Formulário web para idade, pressão arterial, glicemia, temperatura e frequência cardíaca.
- Comparação de dois modelos de Machine Learning e seleção por métrica justificada.
- Explicabilidade local da predição e importância global das variáveis.
- RAG com documentos oficiais e apresentação das fontes recuperadas.
- Explicação por LLM via OpenAI, organizada no fluxo principal com LangChain.
- Persistência dos dados utilizados e dos resultados para logging e auditoria.

2. Dados utilizados

Foi utilizado o ML-Ready Maternal Health Risk Assessment Dataset, selecionado no Kaggle. A descrição atribui a coleta a hospitais, clínicas comunitárias e centros de saúde materna de áreas rurais de Bangladesh. O CSV não contém nomes nem identificadores de paciente.

Campo	Unidade	Papel
Age	anos	Atributo
SystolicBP	mmHg	Atributo
DiastolicBP	mmHg	Atributo
Blood glucose	mmol/L	Atributo
BodyTemp	°F	Atributo
HeartRate	bpm	Atributo
RiskLevel	0 baixo; 1 médio; 2 alto	Alvo

Auditoria do arquivo

- O CSV possui 1014 registros, embora a descrição pública informe 1.013.
- Foram encontradas 562 repetições exatas; restaram 452 linhas únicas.
- Há 35 grupos em que os mesmos atributos aparecem associados a rótulos diferentes.
- O valor HeartRate=7 é um extremo estatístico. Foi mantido por falta de evidência auditável no arquivo para corrigi-lo ou removê-lo.
- SHA-256 do CSV: 1d272d463635f9d4b94f268468253c9dbe1e78e576ee8badb1b773f4d749a752.

3. Preparação e separação dos dados

Os nomes das colunas foram normalizados, os atributos foram convertidos para valores numéricos e valores infinitos foram tratados como ausentes. Os pipelines contêm imputação pela mediana; o pré-processamento é ajustado somente na partição de treino.

As repetições exatas foram removidas antes da divisão. Vetores de atributos iguais foram mantidos no mesmo grupo por StratifiedGroupKFold, inclusive quando os rótulos eram conflitantes. Assim, nenhum vetor idêntico aparece simultaneamente no treino e no teste.

Partição	Registros	Baixo	Médio	Alto	Grupos
Treino	363	188	85	90	332
Teste	89	46	21	22	84

4. Modelos e métricas

Foram treinados exatamente dois candidatos: regressão logística multinomial com padronização e random forest com 300 árvores. Ambos usam balanceamento de classes. A semente aleatória é 42.

Modelo	Accuracy	Precision macro	Recall macro	F1 macro	Recall alto
Regressão logística	59,55%	52,34%	55,22%	53,57%	81,82%
Random forest	69,66%	64,44%	66,78%	65,37%	90,91%

A random forest foi selecionada. Obteve accuracy 69,66%, F1 macro 65,37% e recall de alto risco 90,91%, com 2 falsos negativos de alto risco no holdout.

Por que não usar apenas accuracy?

Accuracy pode esconder desempenho fraco em classes menores. Neste cenário, deixar de identificar um registro rotulado como alto risco tem impacto potencialmente mais relevante do que aumentar a taxa global de acerto. Por isso, a regra definida antes da comparação maximiza primeiro o recall da classe alta; F1 macro e accuracy são desempates. O recall da classe média permaneceu baixo, o que limita a utilização e impede qualquer interpretação diagnóstica.

5. Explicabilidade

A importância global da random forest mostra quanto cada atributo participou das divisões das árvores. Para cada predição, o backend decompõe exatamente a variação de probabilidade ao longo do caminho percorrido em todas as árvores. A soma da base e das contribuições reconstrói a probabilidade, com erro numérico registrado.

Atributo	Importância global
blood_sugar	33,48%
systolic_bp	20,32%
age	15,16%
diastolic_bp	12,43%
heart_rate	10,44%
body_temperature	8,18%

Contribuição não significa causalidade. Ela explica o comportamento do modelo no dataset treinado e não prova que uma variável causou determinado desfecho clínico.

6. Arquitetura da aplicação

Componente	Responsabilidade
Frontend React/TypeScript	Coleta, validação, resultados, fontes e histórico.
API FastAPI	Contrato HTTP, validação e composição dos casos de uso.
Pipeline scikit-learn	Predição, probabilidades e explicabilidade.
LangChain	Orquestra ML → recuperação → explicação.
Retriever TF-IDF	Busca lexical local nas sínteses oficiais.
OpenAI gpt-5.6-luna	Explica resultado e contexto recuperado quando há chave.
SQLite	Registra entrada, resultado, modelo, fontes e uso da LLM.

Frontend e backend são projetos separados, com Dockerfiles próprios. O Docker Compose conecta os containers e preserva o banco de auditoria em volume. A ausência de chave OpenAI não interrompe ML e RAG: a API marca `llm_used=false` e informa que a explicação por LLM não foi executada.

7. LLM e RAG

O modelo padrão configurável é gpt-5.6-luna. O prompt delimita a predição, os fatores e as sínteses recuperadas, exige português do Brasil, proíbe diagnóstico e prescrição, solicita indicação [1], [2] das fontes e obriga declarar insuficiência de informação. A chave é fornecida somente por variável de ambiente.

Quando a LLM está habilitada, classificação, probabilidades, seis valores com suas contribuições, pergunta livre e sínteses recuperadas são enviados à OpenAI.

Base oficial

Documento	Versão	Uso no RAG
Caderneta Brasileira da Gestante	MS, 2026	Alertas, PA e acompanhamento.
Manual de Gestão de Alto Risco	MS, 2022	Estratificação, PA, glicemia e contexto.
Linha de Cuidado do Pré-natal	MS/SAPS, 2021	Planejamento e situações de urgência.
Cuidados Obstétricos em DMG	MS/OPAS/FEBRASGO/SBD, 2021	Contexto do monitoramento glicêmico.

A recuperação é local e determinística por TF-IDF. Cada resultado inclui título, página ou seção, URL oficial, síntese e pontuação de relevância. Os documentos integrais não são redistribuídos.

8. Segurança, responsabilidade e auditoria

- Toda tela e resposta declara que o sistema é apoio e não substitui decisão humana.
- O prompt proíbe diagnóstico definitivo, prescrição e recomendação sem base documental.
- Campos de identificação pessoal não são coletados.
- A interface orienta a não inserir identificadores no campo livre de pergunta.
- Entradas fora do domínio observado pelo modelo são recusadas pelo contrato da API.
- Cada análise recebe UUID e data UTC e persiste os dados utilizados e o resultado.
- O log registra versão do modelo, probabilidades, contribuições, fontes e uso da LLM.
- Falha da LLM gera resposta segura e explícita; não há substituição silenciosa por texto inventado.

9. Limitações

- Após remover repetições exatas, restam apenas 452 registros.
- O mesmo vetor aparece com rótulos conflitantes em 35 grupos.
- O dataset não fornece paciente, tempo, idade gestacional, sintomas, histórico ou desfecho.
- A origem em Bangladesh não demonstra generalização para a população brasileira.
- BodyTemp usa °F; os protocolos brasileiros usam °C.
- Glicemia não informa jejum, pós-prandial ou TOTG e não sustenta critérios diagnósticos.
- HeartRate=7 foi mantido como dado extremo não verificável.
- Recall médio de 33,33% e F1 macro de 65,37% demonstram desempenho limitado.
- A LLM pode errar; sua resposta fica restrita ao contexto recuperado e exige revisão humana.
- O protótipo não possui autenticação: não deve ser exposto à internet nem receber dados reais ou identificáveis.
- Fontes CC BY-NC-SA exigem atribuição, uso não comercial e compartilhamento compatível.

Por essas limitações, a solução é uma demonstração acadêmica. Não foi validada clinicamente e não deve ser implantada em atendimento real sem governança, revisão especializada, avaliação ética, segurança da informação e validação prospectiva.

10. Reprodução e entregáveis

O repositório contém código-fonte, script de treinamento, dataset auditado, artefato versionado, métricas em JSON, frontend, backend, testes, Dockerfiles, Docker Compose, README e este relatório. O treinamento pode ser repetido com `python -m training.train`. A jornada pode ser executada por containers após configurar `OPENAI_API_KEY`.

Referências principais

Dataset Kaggle:

<https://www.kaggle.com/datasets/arshmanhalid/ml-ready-maternal-health-risk-assessment-dataset>

UCI/DOI: <https://doi.org/10.24432/C5DP5D>

Caderneta 2026: <https://www.gov.br/saude/pt-br/assuntos/saude-de-a-a-z/s/saude-da-mulher/publicacoes/caderneta-brasileira-da-gestante.pdf/view>

Manual de Alto Risco: https://bvsmms.saude.gov.br/bvs/publicacoes/manual_gestacao_alto_risco.pdf

Linha de Cuidado: <https://linhasdecuidado.saude.gov.br/portal/pre-natal-baixo-risco/>

Manual DMG:

https://bvsmms.saude.gov.br/bvs/publicacoes/cuidados_obstetricos_diabetes_gestacional_brasil.pdf

OpenAI models: <https://developers.openai.com/api/docs/models>